Por qué funciona: conceptos del Parcial 1

Este documento no deriva fórmulas: explica por qué los resultados del parcial son como son. Cada sección responde una pregunta «¿por qué…?» con la idea, la intuición geométrica y lo que se vio en el cuaderno de solución.

> Todo el parcial es la misma idea vista tres veces: **convertir un problema en geometría de productos internos**. En el punto 1, ajustar un modelo es *proyectar* el vector de respuestas sobre un subespacio. En el punto 2, una distribución se vuelve un *punto* (su embedding de media) y compararlas es medir la distancia entre dos puntos. En el punto 3, la correlación es el *coseno* de un ángulo, primero entre vectores y luego entre matrices de Gram. El kernel es lo que permite hacer esa geometría en espacios enormes sin construirlos: solo se necesitan productos internos, y el kernel los da.

Índice

1 Regresión: por qué MC, MV y MAP dan lo que dan **3**

1.1 ¿Por qué mínimos cuadrados es una proyección? . . . 3
1.2 ¿Por qué hace falta que Φ tenga rango completo? . . . 3
1.3 ¿Por qué el error de entrenamiento no llega a cero? . . . 3
1.4 ¿Por qué el error de prueba es mayor que el de entrenamiento? . . . 3
1.5 ¿Por qué la regularización estabiliza la solución? . . . 4
1.6 ¿Por qué máxima verosimilitud da lo mismo que mínimos cuadrados? . . . 4
1.7 ¿Por qué $\hat{\sigma}^2$ de MV subestima la varianza del ruido? . . . 4
1.8 ¿Por qué MAP es ridge, y por qué $\lambda = \sigma_\eta^2/\sigma_w^2$? . . . 5
1.9 ¿Por qué en el código MC y MV coinciden solo hasta 10^{-9}? . . . 5

2 Kernels y RKHS: por qué basta con productos internos **6**

2.1 ¿Por qué llevar los datos a otro espacio? . . . 6
2.2 ¿Por qué se puede trabajar sin construir φ? . . . 6
2.3 ¿Qué es un RKHS y por qué se llama «reproductor»? . . . 6
2.4 ¿Por qué $\mathbf{K}$ tiene que ser semidefinida positiva? . . . 6

3 Embeddings de media y MMD: por qué una distribución se vuelve un punto **7**

3.1 ¿Por qué existe μ_k y por qué está en el RKHS? . . . 7
3.2 ¿Por qué representa a la distribución? (kernels característicos) . . . 7
3.3 ¿Por qué el MMD mide la diferencia entre distribuciones? . . . 7
3.4 ¿Por qué el estimador sesgado nunca da exactamente cero? . . . 8

3.5 ¿Por qué importa tanto el ancho de banda σ? 8
3.6 ¿Por qué un valor de MMD no basta y hace falta la prueba de permutaciones? 9
3.7 ¿Por qué el MMD no es lo mismo que «se parecen a simple vista»? 9

4 Pearson y su versión en el RKHS: por qué es un coseno 11
4.1 ¿Por qué se centra, y qué hace H? 11
4.2 ¿Por qué Pearson solo ve relaciones lineales? 11
4.3 ¿Por qué comparar matrices de Gram en vez de vectores? 11
4.4 ¿Por qué con kernels lineales en 1D da $\hat{\rho}^2$ y se pierde el signo? 11
4.5 ¿Por qué el kernel gaussiano detecta la relación cuadrática? 11

5 Autoevaluación conceptual 13

1 Regresión: por qué MC, MV y MAP dan lo que dan

1.1 ¿Por qué mínimos cuadrados es una proyección?

El modelo solo puede producir vectores de la forma Φw: combinaciones de las Q columnas de Φ. Ese conjunto es un subespacio de $\mathbb{R}^N$ (el espacio columna). El vector de respuestas t casi nunca está en él, porque tiene ruido. Minimizar $\|t - \Phi w\|$ es buscar el punto del subespacio más cercano a t, y el más cercano es siempre el pie de la perpendicular: la **proyección ortogonal**.

Por eso las ecuaciones normales dicen $\Phi^\top(t - \Phi\hat{w}) = 0$: el residuo es perpendicular a cada columna. No es un truco algebraico, es la condición geométrica de «lo más cerca posible». En el ejercicio a mano, el residuo $(1/6, -1/3, 1/6)$ es ortogonal a las dos columnas de Φ, y esa es la mejor forma de comprobar las cuentas.

> La proyección $\Phi\hat{w}$ siempre es única, aunque $\hat{w}$ no lo sea. Lo que puede fallar no es el punto más cercano, sino la forma de escribirlo con las columnas.

1.2 ¿Por qué hace falta que Φ tenga rango completo?

Si dos columnas de Φ son dependientes (por ejemplo, una es el doble de otra), hay direcciones v con $\Phi v = 0$: moverse en ellas no cambia la predicción. Entonces hay infinitos w con el mismo error y $\Phi^\top\Phi$ no se puede invertir. El rango completo ($\operatorname{rango}\Phi = Q$, lo que exige $N \geq Q$) dice exactamente que no existen esas direcciones «invisibles».

Cuando sí existen, la pseudoinversa escoge, entre todas las soluciones, la de **norma mínima**: la que no pone nada de peso en las direcciones invisibles, porque ese peso no aporta nada al ajuste y solo agranda w. En la SVD se ve directo: Φ^+ invierte los valores singulares distintos de cero y deja en cero los nulos.

1.3 ¿Por qué el error de entrenamiento no llega a cero?

En la clase del 8 de octubre el profesor preguntó si el error «alguna vez da cero». Hay dos razones para que no:

1. **El ruido.** Aunque se acierte el w verdadero, queda $\|\eta\|^2$, que en promedio es $N\sigma^2$. El ruido es, por definición, lo que el modelo no puede predecir.
2. **La forma del modelo.** Si los datos vienen de un seno y el modelo es una recta, ninguna recta pasa por todos los puntos, ni siquiera sin ruido. La salida es llevar los datos con φ a un espacio donde sí se comporten linealmente.

Un detalle fino: con el $\hat{w}$ estimado el error queda un poco *por debajo* del ruido, $(N - Q)\sigma^2$ en promedio, porque los Q parámetros se acomodan a una parte del ruido. Por eso un error de entrenamiento demasiado bajo es una señal de alarma (sobreajuste), no un éxito.

1.4 ¿Por qué el error de prueba es mayor que el de entrenamiento?

El ajuste se hizo para que los datos de entrenamiento quedaran cerca; los de prueba no participaron, así que su ruido no fue «absorbido». En el cuaderno, en 157 de 200 repeticiones el ECM de prueba superó al de entrenamiento, y en promedio fue 0.279 frente a 0.233. Que alguna vez ocurra lo contrario es variabilidad muestral: con solo 60 datos de prueba, el ECM de prueba fluctúa bastante.

1.5 ¿Por qué la regularización estabiliza la solución?

Con la SVD, mínimos cuadrados divide cada componente por un valor singular: $\frac{u_i^\top t}{s_i}$. Si s_i es pequeño, el ruido que haya en $u_i^\top t$ se amplifica muchísimo. La regularización multiplica cada componente por el factor de filtro

$$f_i = \frac{s_i^2}{s_i^2 + \lambda},$$

que vale casi 1 en las direcciones fuertes y casi 0 en las débiles. Es decir, **apaga las direcciones donde los datos casi no tienen información**, que son justamente las que el ruido domina.

El precio es un sesgo: incluso sin ruido, $\hat{w}_\lambda \neq w_*$ porque todo se encoge un poco hacia cero. Se cambia un poco de sesgo por mucha menos varianza. Además $\Phi^\top \Phi + \lambda I$ siempre es invertible, así que la solución existe y es única aunque haya columnas dependientes.

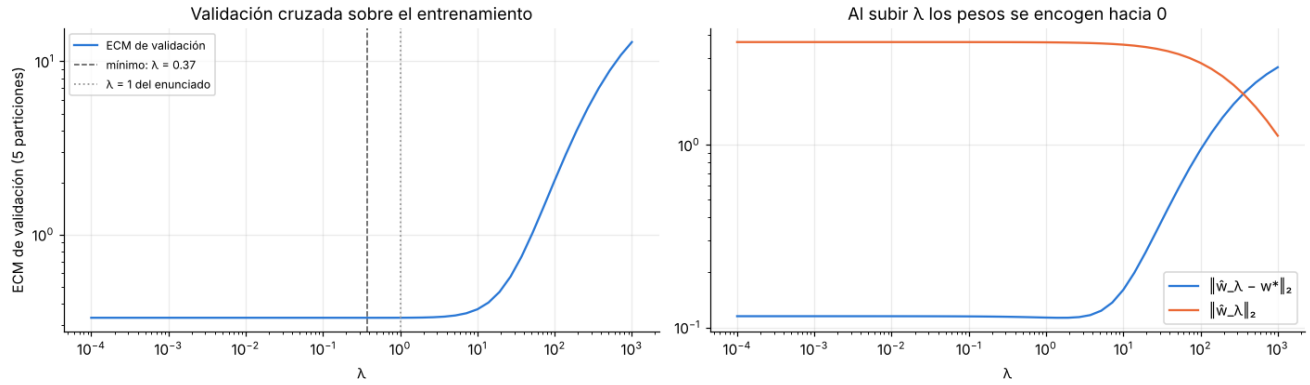


Figura 1. Validación cruzada de λ y cómo se encogen los pesos al subir λ. Los pesos de las direcciones débiles caen primero.

En el parcial, con Φ de 240 filas y número de condición 4.5, todas las direcciones están bien determinadas: por eso ridge con $\lambda = 1$ casi no cambia nada (ECM de prueba 0.2794 frente a 0.2760). La regularización brilla cuando hay pocos datos, muchas características o columnas casi colineales.

1.6 ¿Por qué máxima verosimilitud da lo mismo que mínimos cuadrados?

Porque el ruido es gaussiano. La densidad gaussiana tiene $\exp(-\text{error}^2/2\sigma^2)$; al tomar logaritmo queda exactamente menos la suma de cuadrados. Maximizar la probabilidad de los datos es, entonces, minimizar los cuadrados.

Esto dice algo más profundo: **elegir una función de pérdida es elegir un modelo de ruido**. Si el ruido fuera de Laplace ($e^{-|\text{error}|}$), MV daría la suma de valores absolutos, que es más robusta a datos atípicos. Mínimos cuadrados no es «la» forma de ajustar; es la forma correcta cuando el ruido es gaussiano.

1.7 ¿Por qué $\hat{\sigma}^2$ de MV subestima la varianza del ruido?

MV estima σ^2 con los residuos, $\frac{1}{N}\|t - \Phi\hat{w}\|^2$. Pero esos residuos ya son más chicos que el ruido real, porque $\hat{w}$ se acomodó a los datos (sección anterior): su esperanza es $\frac{N-Q}{N}\sigma^2$. En el cuaderno: $\hat{\sigma}^2 = 0.273$ con MV y 0.298 dividiendo por $N - Q$, para un valor real de 0.25. La diferencia entre N y $N - Q$ importa cuando Q no es pequeño frente a N.

1.8 ¿Por qué MAP es ridge, y por qué $\lambda = \sigma_\eta^2/\sigma_w^2$?

El prior gaussiano $w \sim \mathcal{N}(0, \sigma_w^2 I)$ dice «creo que los pesos son pequeños». Su logaritmo es $-\|w\|^2/2\sigma_w^2$: una penalización cuadrática. Al sumarla con la verosimilitud aparece el problema de ridge.

El cociente se entiende como una **competencia entre dos incertidumbres**: σ_η^2 mide cuánto desconfío de los datos y σ_w^2 cuánto desconfío de mi creencia previa. Si los datos son muy ruidosos (σ_η^2 grande), λ crece y pesa más el prior. Si el prior es muy vago ($\sigma_w^2 \to \infty$), $\lambda \to 0$ y MAP vuelve a ser MC. La regularización deja de ser un «parche» y pasa a ser información previa explícita.

1.9 ¿Por qué en el código MC y MV coinciden solo hasta 10^{-9}?

MC y ridge se resolvieron con la fórmula cerrada; MV y MAP, con un optimizador numérico (L-BFGS-B) sobre el logaritmo de la verosimilitud o del posterior. El optimizador se detiene cuando el gradiente es menor que una tolerancia, no cuando llega al mínimo exacto. La diferencia de 10^{-9} es esa tolerancia, no una diferencia teórica. Por eso el parcial pide «justificar cualquier discrepancia numérica».

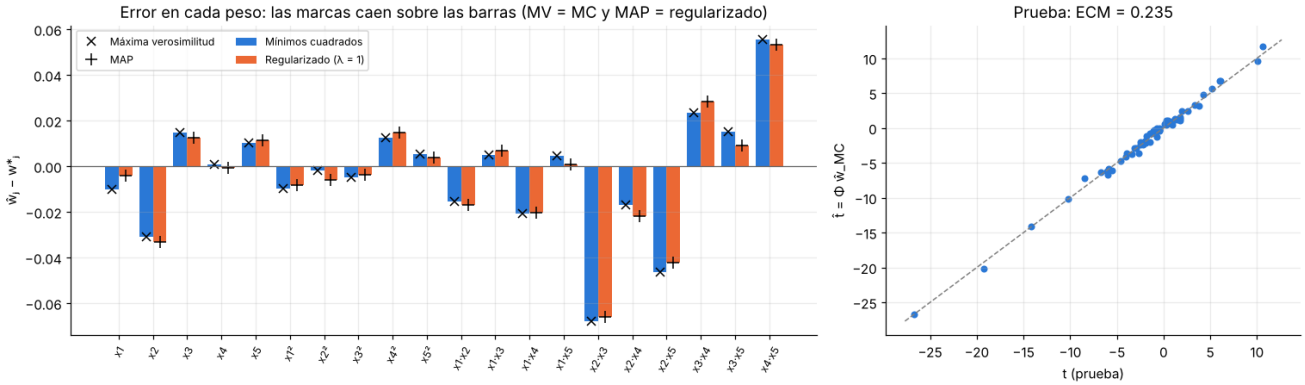


Figura 2. Error de cada peso con los cuatro estimadores: las marcas de MV y MAP caen sobre las barras de MC y ridge.

2 Kernels y RKHS: por qué basta con productos internos

2.1 ¿Por qué llevar los datos a otro espacio?

Una recta no puede seguir a un seno en el espacio original. Pero si cada dato x se lleva a $\varphi(x)$ con más coordenadas (por ejemplo $x, x^2, x^3, \dots$), un modelo lineal en esas coordenadas es no lineal en x. La «recta» se traza en el espacio proyectado, no en el original: esa fue la pregunta del profesor en clase. El modelo sigue siendo lineal *en los parámetros*, y por eso todas las herramientas de mínimos cuadrados siguen sirviendo cambiando X por Φ.

2.2 ¿Por qué se puede trabajar sin construir φ?

Cuando Q es finito y pequeño (como las 20 características del parcial), no hace falta el kernel: se forma Φ y se resuelve. El kernel es necesario cuando Q es enorme o infinito, como en el kernel gaussiano, donde $\Phi^\top\Phi$ ni siquiera existe como matriz.

La salida es que la solución siempre es una combinación de los datos, $\hat{w} = \Phi^\top\alpha$, y entonces todo lo que aparece son productos internos $\varphi(x_n)^\top\varphi(x_m)$. Si una función k da esos productos directamente, nunca hay que construir φ. El sistema pasa de $Q \times Q$ a $N \times N$: se cambia el tamaño de las características por el número de datos.

2.3 ¿Qué es un RKHS y por qué se llama «reproductor»?

Es un espacio de *funciones*, no de vectores. Cada dato x se vuelve una función, $k(x, \cdot)$: una «campana» centrada en x si el kernel es gaussiano. Las funciones del espacio son combinaciones de esas campanas.

«Reproductor» quiere decir que **evaluar una función es un producto interno**: $f(x) = \langle f, k(x, \cdot)\rangle$. Esa propiedad es la que conecta las dos visiones: lo que pasa en el RKHS (geometría de funciones) se calcula con números del kernel (la matriz de Gram). Y en particular $\langle k(x, \cdot), k(z, \cdot)\rangle = k(x, z)$: el kernel es el producto interno entre las representaciones de dos datos.

LOS CUATRO OBJETOS QUE EL PARCIAL PIDE DISTINGUIR

Espacio original	donde viven los datos: $x \in \mathbb{R}^p$ (o una imagen de 784 píxeles).
Espacio de características	donde vive $\varphi(x) \in \mathbb{R}^Q$, con Q finito o infinito.
RKHS $\mathcal{H}_k$	donde viven las funciones $k(x, \cdot)$, μ_k y las funciones testigo.
Formulación matricial	lo que se calcula: $\mathbf{K} \in \mathbb{R}^{N\times N}$, $\mathbf{K}_{nm} = k(x_n, x_m)$.

2.4 ¿Por qué K tiene que ser semidefinida positiva?

Porque es una matriz de productos internos: $a^\top\mathbf{K}a = \|\sum_n a_n\varphi(x_n)\|^2 \geq 0$. Si una función k produce una matriz con un valor propio negativo, no puede ser el producto interno de ningún espacio, y la geometría (distancias, ángulos) deja de tener sentido. Esa es la condición de Mercer: «simétrico definido positivo» es exactamente «es un producto interno en algún espacio».

3 Embeddings de media y MMD: por qué una distribución se vuelve un punto

3.1 ¿Por qué existe μ_k y por qué está en el RKHS?

$\mu_k = \mathbb{E}[k(X, \cdot)]$ es el promedio de las campanas de todos los datos posibles. Que ese promedio exista dentro del espacio no es obvio: un promedio de infinitos elementos podría «salirse». El argumento es el teorema de Riesz: la operación «tomar el valor esperado de f» es lineal y acotada (si $\mathbb{E}\sqrt{k(X,X)} < \infty$), y en un espacio de Hilbert toda operación así es un producto interno con un elemento fijo. Ese elemento es μ_k:

$$\mathbb{E}[f(X)] = \langle f, \mu_k \rangle \quad \text{para toda } f \in \mathcal{H}_k.$$

Así que μ_k es el objeto que «responde» todos los valores esperados. Con el kernel gaussiano, que vale como mucho 1, la condición siempre se cumple.

3.2 ¿Por qué representa a la distribución? (kernels característicos)

Depende del kernel, y aquí está el corazón del punto 2:

- Con el **kernel lineal**, μ_k es solo la media: dos distribuciones con la misma media tienen el mismo embedding.
- Con el **polinómico de grado 2**, guarda media y segundo momento: una gaussiana y una uniforme con la misma media y varianza se confunden.
- Con el **gaussiano**, su φ tiene infinitas coordenadas, que contienen todos los momentos. Dos distribuciones distintas dan embeddings distintos. Un kernel con esa propiedad se llama **característico**.

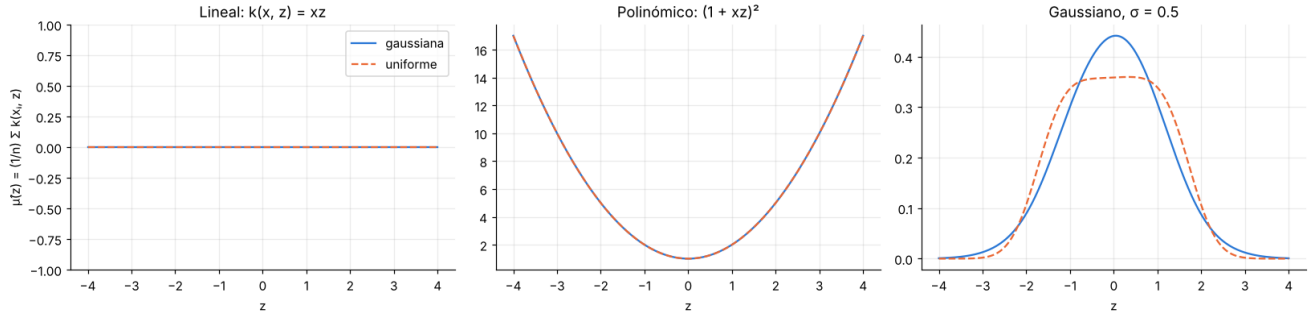


Figura 3. $\hat{\mu}(z)$ de una gaussiana y una uniforme con igual media y varianza: coinciden con los kernels lineal y polinómico, y se separan con el gaussiano.

3.3 ¿Por qué el MMD mide la diferencia entre distribuciones?

Si cada distribución es un punto del RKHS, la distancia entre los puntos, $\|\mu_X - \mu_Y\|$, es la distancia entre distribuciones. Con un kernel característico es 0 *solo* si $P_X = P_Y$.

Hay una lectura equivalente que da la intuición: el MMD es la mayor diferencia de promedios que puede detectar una función suave del RKHS,

$$\text{MMD} = \sup_{\|f\| \le 1} \big(\mathbb{E}f(X) - \mathbb{E}f(Y)\big),$$

y la función que lo logra (la «función testigo») es proporcional a $\mu_X - \mu_Y$: positiva donde abunda X y negativa donde abunda Y. El MMD busca la mejor «pregunta» para distinguir las dos muestras.

3.4 ¿Por qué el estimador sesgado nunca da exactamente cero?

En $\frac{1}{n^2}\sum_{i,j} k(x_i, x_j)$ entran los términos $k(x_i, x_i)$, que comparan cada dato consigo mismo. Para el gaussiano valen 1, mucho más que la similitud típica entre datos distintos. Esos términos suman de más en los dos primeros sumandos y no tienen contraparte en el cruzado, así que el estimador queda inflado en aproximadamente $(\frac{1}{n} + \frac{1}{m})(1 - \mathbb{E}k(X, X'))$. Por eso las comparaciones dentro de MNIST dieron ≈ 0.001 y no 0. El insesgado quita las diagonales y puede dar negativo, lo que es el precio de no tener sesgo.

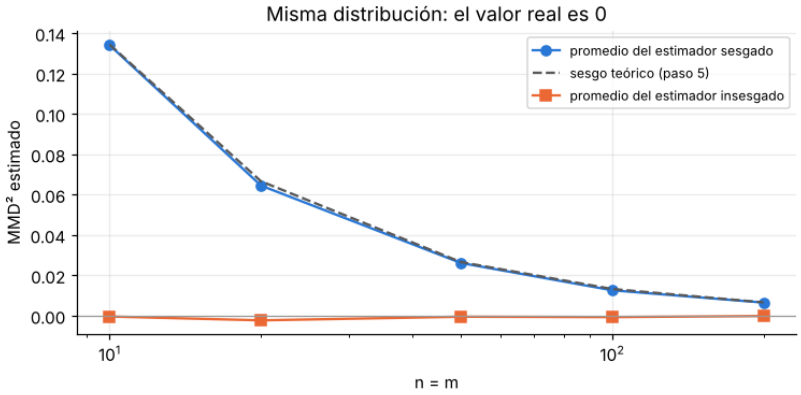


Figura 4. Dos muestras de la misma distribución: el sesgado sigue al sesgo teórico y baja con n; el insesgado queda en 0.

3.5 ¿Por qué importa tanto el ancho de banda σ?

σ es la escala a la que el kernel «mira»:

- σ **muy pequeño:** cada imagen solo se parece a sí misma, $\mathbf{K} \to I$. Todas las muestras parecen igual de distintas y el MMD sesgado tiende a $\frac{1}{n} + \frac{1}{m}$ sin importar los datos.
- σ **muy grande:** todas las imágenes parecen iguales, $\mathbf{K} \to \mathbf{1}\mathbf{1}^\top$, y el MMD tiende a 0. En ese límite el kernel se comporta casi como uno de bajo grado y solo ve diferencias groseras, como las medias.
- **En medio:** el kernel distingue la estructura real. La mediana de las distancias pone σ justo en la escala típica de los datos ($\sigma = 11.1$ en el parcial), de modo que k no es ni casi 0 ni casi 1 para un par típico.

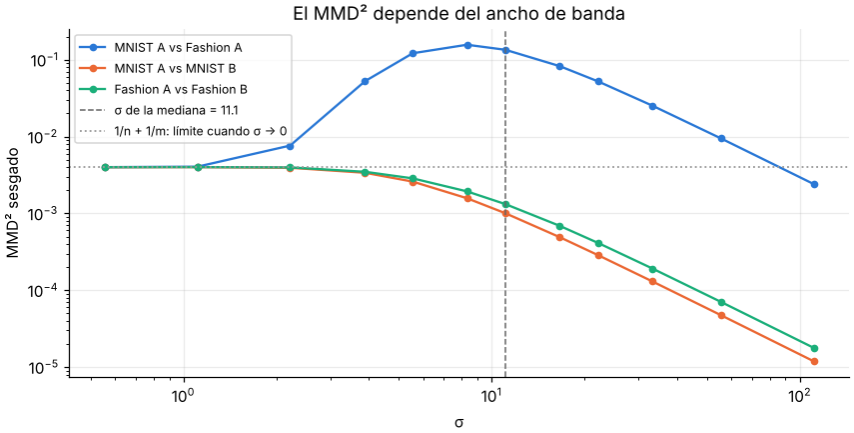


Figura 5. MMD^2 de las tres comparaciones según σ. MNIST frente a Fashion-MNIST se separa de las comparaciones internas en un rango amplio de σ, y todo converge en los extremos.

3.6 ¿Por qué un valor de MMD no basta y hace falta la prueba de permutaciones?

Un número como 0.135 no dice nada solo: el MMD depende de σ, del tamaño de muestra y de los datos, no tiene unidades y no tiene un «umbral universal». La pregunta correcta es: *¿es más grande de lo que saldría por azar si las dos muestras vinieran de la misma distribución?*

La prueba de permutaciones responde eso sin suponer nada de la distribución: si H_0 fuera cierta, las etiquetas «MNIST» y «Fashion» serían intercambiables, así que se mezclan, se reparten al azar y se recalcula el MMD muchas veces. Eso construye la distribución del MMD bajo H_0 con los propios datos. Si el valor observado queda muy por fuera, se rechaza. El $+1$ en $p = \frac{1+\#}{B+1}$ cuenta la partición observada como una más, por eso el p nunca es 0.

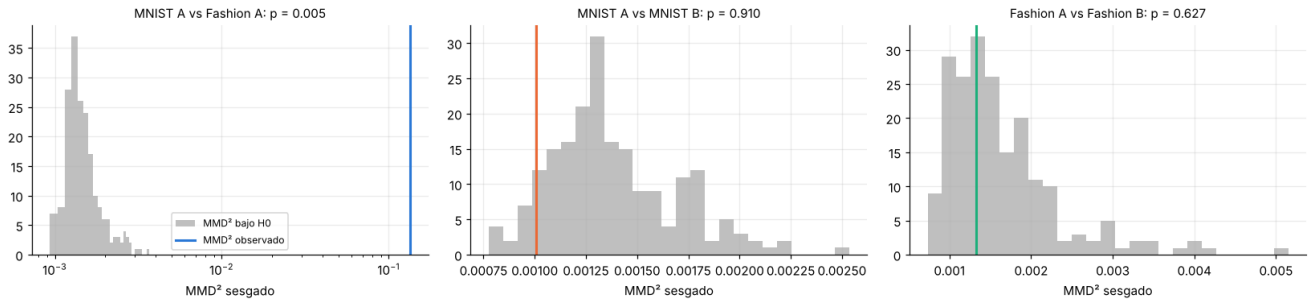


Figura 6. En gris, el MMD^2 al mezclar los grupos; la línea es el valor observado. Solo MNIST frente a Fashion-MNIST queda fuera.

La variabilidad también se ve repitiendo la selección de imágenes: el valor exacto cambia, pero la separación entre «entre datasets» y «dentro del dataset» se mantiene en todas las repeticiones.

3.7 ¿Por qué el MMD no es lo mismo que «se parecen a simple vista»?

En el cuaderno, el 1 y el 7 tienen una similitud promedio alta ($\bar{K}_{17} = 0.695$), pero su MMD^2 es de los más grandes (0.187). La razón es que el MMD compara la similitud *entre* grupos con la similitud *dentro* de cada grupo: $\bar{K}_{11} + \bar{K}_{77} - 2\bar{K}_{17}$. Los unos se parecen muchísimo entre sí ($\bar{K}_{11} = 0.839$, tienen pocos píxeles encendidos), así que un 7 queda lejos de ese grupo tan compacto. Las parejas con MMD^2 más bajo, 4–9 y

5–8, son las que se confunden también al escribirlas a mano.

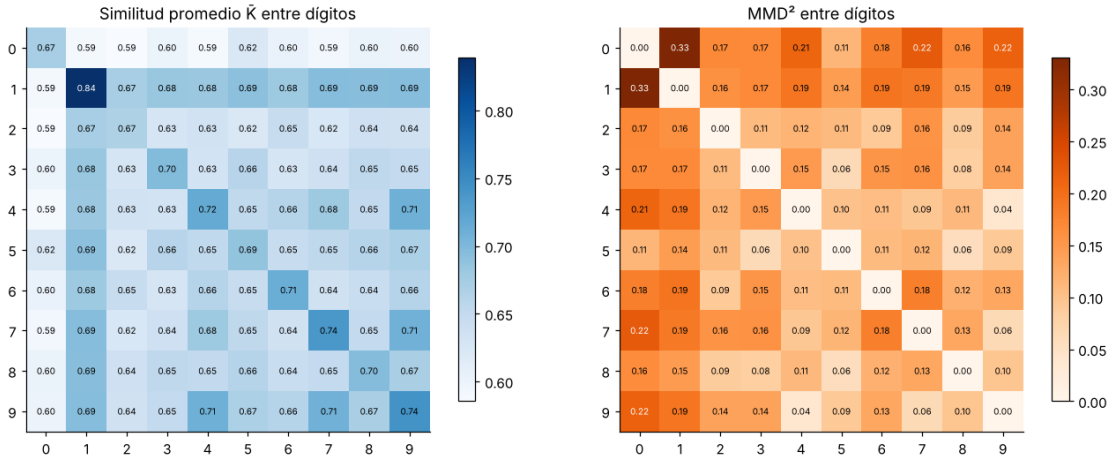


Figura 7. Similitud promedio y MMD^2 entre los diez dígitos de MNIST.

4 Pearson y su versión en el RKHS: por qué es un coseno

4.1 ¿Por qué se centra, y qué hace H?

La correlación pregunta si X e Y *varían juntas*, no si son grandes juntas. Para eso hay que quitar el nivel promedio: $H = I - \frac{1}{N}\mathbf{1}\mathbf{1}^\top$ le resta a cada vector su media. Geométricamente, H es la **proyección ortogonal** sobre el subespacio de vectores de suma cero (perpendicular a $\mathbf{1}$). Por eso es simétrica e idempotente: proyectar dos veces es lo mismo que proyectar una vez, y $H\mathbf{1} = 0$ porque la parte constante es justo lo que se elimina.

Una vez centrados, Pearson es el **coseno del ángulo** entre $H\mathbf{x}$ y $H\mathbf{y}$. De ahí salen todas sus propiedades: está entre -1 y 1 (Cauchy–Schwarz), no cambia si se escala o se traslada una variable (el ángulo no depende de la longitud ni de la media), y cambia de signo si una variable se invierte.

4.2 ¿Por qué Pearson solo ve relaciones lineales?

Porque compara los vectores de valores directamente. Si $y = x^2$ con x simétrica alrededor de 0, la mitad de los puntos sube y la otra mitad baja: el coseno da casi 0 aunque y sea una función exacta de x. Pearson cero no significa independencia.

4.3 ¿Por qué comparar matrices de Gram en vez de vectores?

La matriz de Gram describe *quién se parece a quién* dentro de una variable: $\mathbf{K}_X[i, j]$ dice cuán parecidas son las observaciones i y j según X. Si X e Y están relacionadas, los pares que se parecen en X también se parecen en Y, y las dos matrices tienen el mismo «patrón». El índice ρ_{RKHS} es el coseno entre esas matrices centradas, con el producto de Frobenius. Ventajas:

- X e Y pueden tener dimensiones distintas ($P \neq Q$): las dos matrices son $N \times N$.
- Con un kernel no lineal (gaussiano), las similitudes capturan relaciones no lineales.

El centrado $H\mathbf{K}H$ es el mismo que en Pearson, ahora aplicado en el espacio de características: le resta a cada $\varphi(x_n)$ el promedio de todos (es la matriz de Gram de los φ centrados).

4.4 ¿Por qué con kernels lineales en 1D da $\hat{\rho}^2$ y se pierde el signo?

Con el kernel lineal, $\mathbf{K}_Y = \mathbf{y}\mathbf{y}^\top$, y esa matriz es la misma para $\mathbf{y}$ y para $-\mathbf{y}$: invertir todos los valores no cambia quién se parece a quién. El índice se queda con la *fuerza* de la relación y pierde su *dirección*. Algebraicamente, cada traza da un producto interno al cuadrado, y $\frac{(\mathbf{x}^\top H\mathbf{y})^2}{(\mathbf{x}^\top H\mathbf{x})(\mathbf{y}^\top H\mathbf{y})} = \hat{\rho}^2$. En el cuaderno: $\hat{\rho} = \pm 0.6565$ y $\rho_{\text{RKHS}} = 0.4309$ en los dos casos.

4.5 ¿Por qué el kernel gaussiano detecta la relación cuadrática?

Con el gaussiano, la similitud entre dos observaciones depende de su distancia. Si $y = x^2$, los puntos con x cercanos tienen y cercanos, así que las dos matrices de similitudes se parecen aunque la relación no sea lineal. Pearson y el alineamiento lineal no lo ven; el alineamiento gaussiano sí.

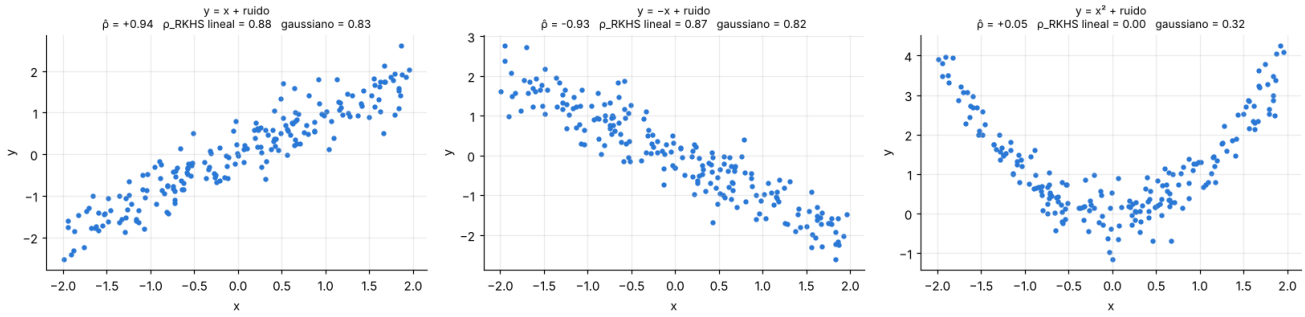


Figura 8. Tres relaciones entre x e y. Pearson detecta las lineales; solo el alineamiento con kernel gaussiano detecta la cuadrática.

En los dos puntos se usa el mismo truco: llevar los datos al RKHS y hacer allí algo clásico. En el 2, *promediar* (embedding) y medir una *distancia* (MMD). En el 3, *centrar* y medir un *ángulo* (alineamiento). Con el kernel lineal se recupera lo clásico: diferencia de medias y Pearson al cuadrado. Con el gaussiano, los dos detectan diferencias o dependencias que lo clásico no ve.

5 Autoevaluación conceptual

Responde sin hacer cuentas. Las respuestas están en el recuadro verde de abajo; tápalo antes de empezar.

1. Si $N < Q$, ¿puede ser única la solución de mínimos cuadrados? ¿Y la de ridge?
2. ¿Por qué un error de entrenamiento exactamente 0 con datos ruidosos es mala señal?
3. Un compañero dice: «MAP es mejor que MV porque usa más información». ¿Cuándo es cierto y cuándo no?
4. ¿Por qué con 240 datos y 20 características ridge casi no cambia el resultado?
5. ¿Qué diferencia hay entre $\varphi(x)$ y $k(x, \cdot)$?
6. ¿Por qué el kernel lineal no sirve para comparar MNIST con Fashion-MNIST si las dos tuvieran el mismo píxel promedio?
7. Si el MMD^2 sesgado entre dos muestras de MNIST dio 0.001, ¿significa que las muestras son distintas?
8. ¿Qué pasa con el MMD si se usa un σ diez veces más pequeño que la mediana?
9. ¿Por qué el p-valor de la prueba de permutaciones con $B = 200$ no puede ser menor que 0.005?
10. Si $\hat{\rho}_{XY} = 0$, ¿son X e Y independientes?
11. ¿Por qué H aparece a ambos lados de $\mathbf{K}$ en $H\mathbf{K}H$?
12. Si $\rho_{\text{RKHS}} = 0.43$ con kernels lineales en 1D, ¿cuánto vale $\hat{\rho}$?

1. MC no: con $N < Q$ el rango es como mucho $N < Q$ y hay direcciones invisibles. Ridge sí, porque $\Phi^\top \Phi + \lambda I$ siempre es invertible.
2. Porque el mínimo esperado es $(N - Q)\sigma^2 > 0$: si da 0, el modelo memorizó el ruido y generalizará mal.
3. Es cierto si el prior es razonable y hay pocos datos. Con muchos datos los dos coinciden, y un prior equivocado empeora el resultado.
4. Porque Φ está bien condicionada (número de condición 4.5): todos los s_i^2 son mucho mayores que $\lambda = 1$ y los factores de filtro valen casi 1.
5. $\varphi(x)$ es un vector de características; $k(x, \cdot)$ es una función en el RKHS. Están relacionados por $k(x, z) = \varphi(x)^\top \varphi(z)$, y $k(x, \cdot)$ es la versión «función» de $\varphi(x)$.
6. Con el kernel lineal, el MMD^2 es la distancia entre las imágenes promedio; si fueran iguales, daría 0 aunque los datasets sean completamente distintos.
7. No. El estimador sesgado nunca da 0; ese valor es del orden del sesgo $\frac{1}{n} + \frac{1}{m}$. Solo una prueba formal lo puede decir.
8. $\mathbf{K}$ se acerca a la identidad, todas las imágenes parecen distintas de todas, y los tres MMD^2 se acercan a $\frac{1}{n} + \frac{1}{m} = 0.004$: se pierde la capacidad de distinguir.

9. Porque $p = \frac{1+\#}{B+1} \geq \frac{1}{201}$: es la resolución de la prueba. Para un p más chico hacen falta más permutaciones.

10. No. Pearson cero solo dice que no hay relación *lineal*; $y = x^2$ con x simétrica da $\hat{\rho} \approx 0$.

11. Porque centra las filas y las columnas: equivale a centrar los $\varphi(x_n)$ antes de hacer los productos internos.

12. $\hat{\rho} = \pm\sqrt{0.43} \approx \pm 0.66$: el signo no se puede recuperar.