Parcial 1: Teoría de Aprendizaje de Máquina - 2026-2

Profesor: Diego Armando Pérez Rosero

Tema: Métodos kernel, espacios de características y formulación matricial

Instrucciones

- Responda de manera clara, ordenada y completamente justificada.
- No se evaluarán resultados finales sin desarrollo matemático.
- Cuando corresponda, presente cada derivación paso a paso, indicando las propiedades utilizadas.
- Mantenga una notación consistente en todo el documento.
- En los desarrollos matriciales, indique con claridad las dimensiones de los objetos involucrados cuando sea pertinente.
- En los puntos relacionados con kernels, distinga explícitamente entre:
  - espacio original;
  - espacio de características;
  - RKHS asociado;
  - formulación matricial inducida.
- Se valorará especialmente la coherencia conceptual, la rigurosidad matemática y la capacidad de conectar las distintas representaciones del problema.

Preguntas

1. **Regresión en espacios de características: mínimos cuadrados, máxima verosimilitud y máximo a posteriori.**
   Sea un conjunto de datos i.i.d.

$$\{(x_n, t_n)\}_{n=1}^{N}, \qquad x_n \in \mathbb{R}^P, \quad t_n \in \mathbb{R},$$

   y considere un mapeo explícito $\phi : \mathbb{R}^P \to \mathbb{R}^Q$ y el modelo de regresión

$$t_n = \phi(x_n)^\top w + \eta_n, \qquad w \in \mathbb{R}^Q,$$

   donde, cuando corresponda, se asumirá $\eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2)$. Sea $\Phi \in \mathbb{R}^{N \times Q}$ la matriz cuyas filas son $\phi(x_n)^\top$, y $t \in \mathbb{R}^N$ el vector de respuestas.

   1.1 Mínimos cuadrados. Plantee la función objetivo y deduzca, paso a paso, el estimador por mínimos cuadrados, incluyendo las condiciones necesarias para la existencia y unicidad de la solución.

   1.2 Mínimos cuadrados regularizados. Formule el problema con penalización cuadrática $\lambda\|w\|_2^2$, con $\lambda > 0$, y derive su solución cerrada. Explique el efecto del parámetro de regularización.

   1.3 Máxima verosimilitud. Bajo el supuesto de ruido gaussiano i.i.d., construya la función de verosimilitud y su logaritmo, y obtenga el estimador de w por máxima verosimilitud. Explicite su relación con mínimos cuadrados.

   1.4 Máximo a posteriori. Suponga además el prior $w \sim \mathcal{N}(0, \sigma_w^2 I_Q)$. A partir de la regla de Bayes, deduzca el problema de optimización MAP y su solución; establezca la relación entre σ_η^2, σ_w^2 y la regularización cuadrática.

1.5 Implementación y análisis. Implemente y compare los cuatro enfoques anteriores en Python usando $N = 300$, $P = 5$ y $Q = 20$, con $\Phi : \mathbb{R}^{N\times P} \to \mathbb{R}^{N\times Q}$. Para generar los datos:

- Fije una semilla aleatoria y genere las filas de $X \in \mathbb{R}^{N\times P}$ de forma i.i.d. con entradas $\mathcal{N}(0, 1)$.
- Construya una transformación reproducible $\Phi(X)$ de $Q = 20$ características: concatene las $P = 5$ columnas originales, sus cuadrados (5 columnas) y los $\binom{5}{2} = 10$ productos por pares de columnas distintas. Indique el orden utilizado.
- Genere $w_* \in \mathbb{R}^{20}$ con entradas i.i.d. $\mathcal{N}(0, 1)$ y $\eta_n \sim \mathcal{N}(0, 0{,}5^2)$ de forma independiente. Defina $t = \Phi(X)w_* + \eta$.
- Separe aleatoriamente los datos en entrenamiento (80 %) y prueba (20 %). Ajuste los cuatro estimadores usando *únicamente* entrenamiento; para los modelos regularizados use, por ejemplo, $\lambda = 1$ y el prior compatible $\sigma_w^2 = \sigma_\eta^2/\lambda$, según la convención de función objetivo empleada.
- Reporte el error cuadrático medio en entrenamiento y prueba, y $\|\hat{w} - w_*\|_2$. Compare las soluciones y explique las coincidencias esperadas entre mínimos cuadrados y máxima verosimilitud, y entre regularización cuadrática y MAP. Justifique cualquier discrepancia numérica.

2. **Espacios RKHS, embeddings de media y discrepancia entre distribuciones.**
Sea $k : \chi \times \chi \to \mathbb{R}$ un kernel simétrico definido positivo, y sea $\mathcal{H}_k$ el espacio de Hilbert con núcleo reproductor asociado.

2.1 Defina rigurosamente el embedding de media asociado a una variable aleatoria X:

$$\mu_k = \mathbb{E}[k(X, \cdot)].$$

2.2 Explique por qué $\mu_k \in \mathcal{H}_k$ e interprete geométricamente su significado como representante de la distribución de X en el espacio RKHS.

2.3 Discrepancia máxima de medias (MMD). Sean dos variables aleatorias independientes $X \sim P_X$ y $Y \sim P_Y$, definidas sobre un mismo dominio $\mathcal{X}$, con embeddings de media en el RKHS $\mathcal{H}_k$:

$$\mu_X = \mathbb{E}[k(X, \cdot)], \qquad \mu_Y = \mathbb{E}[k(Y, \cdot)].$$

La distancia cuadrática entre dichos embeddings se define mediante

$$\boxed{\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k}.}$$

Considere dos muestras independientes $\{x_i\}_{i=1}^n$ y $\{y_j\}_{j=1}^m$, extraídas de P_X y P_Y, respectivamente. **Demuestre**, a partir de la expresión anterior, que el estimador empírico *sesgado* se puede escribir en la siguiente forma matricial:

$$\boxed{\widehat{\mathrm{MMD}}_b^{\,2} = \frac{1}{n^2}\mathbf{1}_n^\top \mathbf{K}_{XX}\mathbf{1}_n + \frac{1}{m^2}\mathbf{1}_m^\top \mathbf{K}_{YY}\mathbf{1}_m - \frac{2}{nm}\mathbf{1}_n^\top \mathbf{K}_{XY}\mathbf{1}_m.}$$

Aquí $\mathbf{K}_{XX} \in \mathbb{R}^{n\times n}$, $\mathbf{K}_{YY} \in \mathbb{R}^{m\times m}$ y $\mathbf{K}_{XY} \in \mathbb{R}^{n\times m}$ son las matrices de Gram correspondientes. En la demostración desarrolle los productos internos, utilice la propiedad reproductora para llegar a las expresiones con el kernel, establezca la versión empírica y justifique las dimensiones de cada término. Distinga el estimador sesgado de la formulación poblacional.

2.4 Implementación con MNIST y Fashion-MNIST. Implemente el estimador empírico de MMD^2 del punto anterior para comparar ambas distribuciones:

- Seleccione 1 000 imágenes del conjunto de entrenamiento de cada dataset, con una semilla fija, y divídalas aleatoriamente en dos grupos disjuntos de 500 imágenes. Para la comparación entre datasets utilice el primer grupo de cada uno ($n = m = 500$). Convierta cada imagen de 28×28 píxeles en un vector de 784 componentes normalizado a $[0, 1]$.

- Construya las matrices de Gram K_{XX}, K_{YY} y K_{XY} mediante un kernel gaussiano $k(u, v) = \exp(-\|u - v\|_2^2/(2\sigma^2))$. Seleccione $\sigma > 0$ justificadamente, por ejemplo, mediante la mediana de distancias entre pares de imágenes de la muestra combinada; use el *mismo* σ en todas las comparaciones.
- Calcule y reporte MMD^2 entre MNIST y Fashion-MNIST y, como referencia, entre dos particiones disjuntas de 500 imágenes de MNIST y entre dos particiones disjuntas de 500 imágenes de Fashion-MNIST. No utilice etiquetas de clase para construir las comparaciones.
- Presente la expresión matemática utilizada, las dimensiones de cada matriz, los resultados numéricos y sus respectivas conclusiones. Discuta la influencia del ancho de banda del kernel, la variabilidad muestral y los límites de interpretar un valor de MMD sin un procedimiento formal de contraste de hipótesis.

3. **Índice de correlación de Pearson: espacio original y RKHS.**

3.1 **Coeficiente de Pearson en el espacio original.** Sean X y Y dos variables aleatorias escalares, con varianzas positivas, y sean $\mathbf{x}, \mathbf{y} \in \mathbb{R}^{N\times 1}$ los vectores de N observaciones emparejadas. A partir de la definición

$$\rho_{XY} = \frac{\mathbb{E}[(X - \mu_X)(Y - \mu_Y)]}{\sqrt{\mathbb{E}[(X - \mu_X)^2]\,\mathbb{E}[(Y - \mu_Y)^2]}},$$

demuestre que el coeficiente de Pearson muestral puede expresarse matricialmente como

$$\boxed{\hat{\rho}_{XY} = \frac{\mathbf{x}^\top \mathbf{H}\mathbf{y}}{\sqrt{(\mathbf{x}^\top \mathbf{H}\mathbf{x})(\mathbf{y}^\top \mathbf{H}\mathbf{y})}}}, \qquad \mathbf{H} = \mathbf{I}_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top.$$

Justifique el paso de las medias y sumatorias a la forma matricial, el centrado y las dimensiones.

3.2 **Correlación matricial en RKHS.** Sean dos variables aleatorias vectoriales $X \in \mathbb{R}^P$ y $Y \in \mathbb{R}^Q$, con N observaciones emparejadas, y sean k_X y k_Y sus respectivos kernels con matrices de Gram $\mathbf{K}_X, \mathbf{K}_Y \in \mathbb{R}^{N\times N}$. Partiendo del producto interno normalizado entre las matrices de Gram centradas, **demuestre** que el índice de alineamiento centrado en RKHS se expresa como

$$\boxed{\rho_{\text{RKHS}}(\mathbf{K}_X, \mathbf{K}_Y) = \frac{\text{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_Y\mathbf{H})}{\sqrt{\text{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_X\mathbf{H})\ \text{tr}(\mathbf{K}_Y\mathbf{H}\mathbf{K}_Y\mathbf{H})}}}.$$

Utilice $\mathbf{K}_{X,c} = \mathbf{H}\mathbf{K}_X\mathbf{H}$ y $\mathbf{K}_{Y,c} = \mathbf{H}\mathbf{K}_Y\mathbf{H}$ para desarrollar la demostración desde productos internos y sumatorias hasta trazas; justifique sus dimensiones. Finalmente, para kernels lineales y $P = Q = 1$, **demuestre** que $\rho_{\text{RKHS}} = \hat{\rho}_{XY}^2$ y explique la pérdida del signo. *Nota:* el índice de 3.2 es alineamiento centrado de kernels, no el coeficiente de Pearson clásico; suponga denominadores distintos de cero.